Bitirme Projesi 2 İlerleme Raporu

Mühendislik ve Doğa Bilimleri Fakültesi

YAZILIM MÜHENDİSLİĞİ BÖLÜMÜ

TÜRKÇE OTEL YORUMLARININ OTOMATİK DUYGU ETİKETLEME VE AÇIKLANABİLİR YAPAY ZEKA İLE İNCELENMESİ

Öğrenci: Ahmet Dülger – Muhammed Esat Demir
Öğrenci Numarası: 220911408 - 220911766

Danışman(lar): Doktor Öğretim Üyesi İLKAY YELMEN

İstanbul
Nisan 2026

ÖĞRENCİ BEYANI

Bu raporda sunulan tüm çalışmalar tarafımızdan gerçekleştirilmiştir. Başka kaynaklardan yararlanılan tüm içerikler açıkça belirtilmiş ve ilgili kaynaklara uygun biçimde atıf yapılmıştır. Projenin tasarımı, geliştirilmesi, raporlanması ve sunumu aşamalarında bilimsel etik ilkelere ve akademik kurallara titizlikle uyulmuş; izinsiz herhangi bir yardım alınmamış, başka kişi veya kişilere ait çalışmalar kendi çalışmamız gibi gösterilmemiştir.

Ayrıca, grup çalışması kapsamında her bir öğrencinin katkısı doğru şekilde belirtilmiş olup, gruptaki başka bir öğrencinin çalışması için yanlışlıkla kredi verilmemiş ve başka bir öğrencinin yaptığı çalışma için haksız şekilde kredi alınmamıştır. Bitirme Projesi süresince belirtilen tüm kurallara ve yükümlülüklere uyduğumuzu beyan ederiz.

Ahmet Dülger

Muhammed Esat Demir

Özet

Bu çalışmada, çevrimiçi platformlardan elde edilen Türkçe otel yorumları üzerinde otomatik duygu analizi gerçekleştirilmiş ve model kararlarının açıklanabilir yapay zekâ (XAI) yöntemleriyle incelenmesine yönelik bir altyapı oluşturulması amaçlanmıştır. Projenin ilk aşamasında farklı kaynaklardan toplanan yorumlar birleştirilmiş, ön işleme ve otomatik etiketleme adımlarının ardından BERTurk tabanlı bir sınıflandırma modeli geliştirilmiş ve başlangıç aşamasında %84,3 doğruluk ile 0,77 Macro-F1 skoru elde edilmiştir.

İkinci aşamada, bu performansın özellikle makine çevirisi içeren veri kaynaklarından etkilendiği gözlemlenmiş ve veri seti yeniden yapılandırılmıştır. Bu kapsamda yaklaşık 12.000 yorum üzerinde manuel ve yapay zekâ destekli etiket düzeltmeleri gerçekleştirilmiş, daha tutarlı etiket yapısı elde etmek amacıyla kısa ve doğrudan yorumlara odaklanan bir veri temizleme stratejisi benimsenmiştir.

Model geliştirme sürecinde farklı veri dengeleme ve eğitim yaklaşımları karşılaştırmalı olarak analiz edilmiştir. Oversampling yönteminin modelde ezberleme eğilimini artırdığı gözlemlenmiş, bu nedenle veri çoğaltma yöntemleri terk edilerek class-weight tabanlı yaklaşımlar tercih edilmiştir. Bu doğrultuda Weighted Cross Entropy, Focal Loss ve Weight Smoothing gibi kayıp fonksiyonları kontrollü deneylerle değerlendirilmiştir.

Ayrıca BERTurk, XLM-RoBERTa ve mDeBERTa-v3 modelleri üzerinde karşılaştırmalı analizler gerçekleştirilmiş ve çoklu seed kullanılarak performans kararlılığı incelenmiştir. Nihai model karşılaştırmaları BERTurk ve XLM-RoBERTa modelleri üzerinde yoğunlaştırılmıştır. Elde edilen bulgular, Türkçe için özelleştirilmiş BERTurk modelinin özellikle nötr sınıf ayrımı ve genelleme kabiliyeti açısından daha istikrarlı sonuçlar verdiğini göstermiştir. Nihai model olarak seçilen yapı ile yaklaşık %79 doğruluk ve 0,75 civarında Macro-F1 skoru elde edilmiştir.

Bu çalışma sonucunda, yalnızca model doğruluğunu artırmaya odaklanan yaklaşımların ötesine geçilerek, veri kalitesi, etiket güvenilirliği ve model genellenebilirliği açısından daha sağlam bir deneysel yapı oluşturulmuştur. Başka bir deyişle, daha yüksek ancak yapay olarak şişirilmiş performans değerleri yerine, gerçek veri dağılımını daha doğru yansıtan ve genellenebilirliği yüksek bir model tercih edilmiştir. Projenin devamında, hata analizi ve XAI yöntemleri (SHAP, LIME) kullanılarak model kararlarının şeffaf biçimde yorumlanması hedeflenmektedir.

Anahtar Kelimeler:

Duygu Analizi, Türkçe Otel Yorumları, Transformer Modelleri, BERTurk, XAI

İçindekiler

Beyan i
Özet ii
İçindekiler iii
Tablolar Listesi v
Şekiller Listesi vi
Kısaltmalar Listesi vii
Giriş 1
1. Duygu Analizi ve Problem Tanımı 2
1.1. Çalışmanın Amacı ve Kapsamı 3
1.1.1. Bilimsel Katkılar 4
Literatür Taraması 5
2. Duygu Analizi Çalışmaları 6
2.1. Türkçe Duygu Analizi ve Transformer Modeller 6
2.1.1. Açıklanabilir Yapay Zekâ Yaklaşımları 7
Metodoloji 8
3. Veri Toplama ve Veri Kaynakları 9
3.1. Kullanılan Veri Kaynakları 9
3.2. Veri Standardizasyonu 10
3.3. Etiketleme Stratejisi 10
3.3.1. Üç Sınıflı Duygu Etiketleme 10
3.3.2. Etiket Doğruluğu ve Veri Revizyon Süreci 10
3.4. Veri Temizleme ve Ön İşleme 11
3.5. Kaggle Verisi ve Veri Kalitesi Analizi 11
3.6. Veri Bölme (Train/Validation/Test) 12
3.7. Sınıf Dengesizliği ve Veri Dengeleme Yöntemleri 12
3.7.1 Oversampling Yaklaşımı 12
3.7.2 Class-Weight Yaklaşımı 13
3.8. Model ve Eğitim Süreci 13
3.9. Loss(Kayıp) Fonksiyonlarının Karşılaştırmalı Analizi 14

3.10. Model Karşılaştırmaları ve Stabilite Analizi 14
3.11. Donanım ve Eğitim Ortamı.....15
Bulgular ve Deney Sonuçları 16
4.1 Veri Kaynağının Model Performansına Etkisi.....17
4.2 Loss Function Karşılaştırılması 18
4.2.1. Focal Loss Eğitim Süreci 18
4.3. Multi-Seed Stabilite Analizi ve Model Karşılaştırması 20
4.4. Confusion Matrix Analizi 21
4.5. Nihai Model Seçimi 22
Tartışma, Sınırlamalar ve Gelecek Çalışmalar 23
5.1. Ana Bulguların Tartışılması.....24
5.2. Teorik ve Operasyonel Sınırlamalar 25
5.3. Geleceğe Yönelik Araştırma Yol Haritası 26
5.4. Genel İlerleme Değerlendirmesi ve Zaman Çizelgesine Uyum 27
Teşekkür.....28
Ekler 29
Kaynakça 32

Tablolar

Çizelge 1. Veri Kaynağının Model Performansına Etkisi. 17
Çizelge 2. Loss Function Deney Sonuçları 19
Çizelge 3. Model Karşılaştırması 21
Çizelge 4. Test Kümesi Sınıflandırma Raporu. 29
Çizelge 5. Confusion Matrix 29
Çizelge 6. Veri Bölme ve Sınıf Dağılımı 29
Çizelge 7. Kullanılan Python Kütüphaneleri 31

Şekiller

Şekil 1. Veri İşleme ve Modelleme Pipeline'ı. 9
Şekil 2. Veri Azaltma Süreci. 18
Şekil 3. Focal Loss Eğitim Süreci. 18
Şekil 4. BERTurk ve XLM-RoBERTa Modellerinin Karşılaştırmalı Performansı. 20
Şekil 5. WCE ile Eğitilen BERTurk Modeline Ait Confusion Matrix(No-Kaggle). 21

Kısaltmalar Listesi

API	Application Programming Interface
BERT	Bidirectional Encoder Representations from Transformers
CSV	Comma-Separated Values
CUDA	Compute Unified Device Architecture
F1	F1-score (Harmonic mean of precision and recall)
GPU	Graphics Processing Unit
HTTP	Hypertext Transfer Protocol
LIME	Local Interpretable Model-agnostic Explanations
NLP	Natural Language Processing
SHAP	SHapley Additive exPlanations
WCE	Weighted Cross Entropy
XAI	Explainable Artificial Intelligence
XLM-R	Cross-lingual Language Model – RoBERTa

Bölüm 1:

Giriş

1. Duygu Analizi ve Problem Tanımı

Büyük hacimli kullanıcı geri bildirimlerinin çevrimiçi platformlar aracılığıyla hızla artması, özellikle turizm sektöründe metinsel verilerin stratejik bir kaynak hâline gelmesine neden olmuştur. Otel işletmeleri açısından kullanıcı yorumları; hizmet kalitesinin değerlendirilmesi, müşteri memnuniyetinin ölçülmesi ve iyileştirme alanlarının belirlenmesi için kritik öneme sahiptir **[1]**. Ancak bu yorumların manuel olarak analiz edilmesi hem zaman alıcı hem de ölçeklenebilir değildir. Bu nedenle, büyük ölçekli kullanıcı geri bildirimlerinin etkin biçimde analiz edilebilmesi için otomatik duygu analizi yöntemlerine olan ihtiyaç giderek artmaktadır. Türkçe doğal dil işleme (NLP) alanında yapılan çalışmalar, İngilizceye kıyasla daha sınırlı veri setleri ve kaynaklar üzerinden yürütülmektedir **[2] [10]**. Özellikle Türkçe otel yorumları gibi alan-özel veri setlerinin eksikliği, yüksek performanslı duygu analizi modellerinin geliştirilmesini zorlaştırmaktadır. Bununla birlikte, literatürdeki güncel ve kapsamlı çalışmalar, derin öğrenme ve Transformer tabanlı metin sınıflandırma yaklaşımlarının (BERT, RoBERTa, ELECTRA vb.) doğal dil işleme görevlerinde yüksek başarı ve genelleme yeteneği sergilediğini ortaya koymaktadır **[3] [15] [16]**. Ancak bu modern mimariler bağlamsal temsilleri başarıyla öğrenebilseler de, karar süreçlerinin çoğu zaman "kara kutu" niteliğinde olması model çıktılarının yorumlanabilirliğini azaltmaktadır. Bu bağlamda, model tahminlerinin şeffaflığını artırmak amacıyla literatürde SHAP ve LIME gibi açıklanabilir yapay zekâ (XAI) yöntemleri öne çıkmaktadır **[7] [8]**.

Son yıllarda yapılan çalışmalar, duygu analizi probleminin yalnızca model mimarisi ile değil; veri kalitesi, etiket doğruluğu ve sınıf dağılımı gibi faktörlerle doğrudan ilişkili olduğunu göstermektedir. Özellikle otomatik etiketleme ve makine çevirisi kullanılarak oluşturulan veri setlerinde, model performansını yapay olarak yükseltebilen ancak gerçek dünya genellenebilirliğini düşüren durumlar ortaya çıkabilmektedir.

Bu çalışma, Türkçe otel yorumları özelinde yalnızca yüksek performanslı bir duygu analizi modeli geliştirmeyi değil, aynı zamanda veri kalitesi ile model genellenebilirliği arasındaki ilişkiyi deneysel olarak analiz ederek daha güvenilir ve açıklanabilir bir analiz altyapısı oluşturmayı hedeflemektedir. Böylece, hem akademik çalışmalar hem de sektörel uygulamalar için daha güvenilir ve genellenebilir bir referans çerçevesi sunulması amaçlanmaktadır.

1.1 Çalışmanın Amacı ve Kapsamı

Bu çalışmanın temel amacı, çeşitli çevrimiçi platformlardan elde edilen Türkçe otel yorumlarını tek ve standart bir veri setinde birleştirerek 3 sınıflı (negatif, nötr, pozitif) duygu analizi gerçekleştirmektir. Bu kapsamda, otomatik etiketleme stratejileri kullanılarak büyük ölçekli bir veri seti oluşturulmuş ve Türkçenin morfolojik yapısına uygun olarak ön-eğitilmiş Transformer tabanlı modeller ile sınıflandırma performansı değerlendirilmiştir **[3] [4]**.

Projenin ilk aşamasında veri toplama, veri ön işleme ve BERTurk modeli ile temel bir sınıflandırma altyapısı kurulmuş; başlangıç deneylerinde yüksek doğruluk değerleri elde edilmiştir. Ancak ikinci dönem çalışmalarında, bu performansın veri seti içeriğinden önemli ölçüde etkilendiği gözlemlenmiş ve özellikle makine çevirisi içeren veri kaynaklarının model sonuçlarını yapay biçimde iyileştirebildiği tespit edilmiştir.

Bu doğrultuda çalışmanın kapsamı yeniden tanımlanarak veri seti kapsamlı biçimde revize edilmiştir. Bu süreçte yaklaşık 12.000 yorum üzerinde önce manuel inceleme gerçekleştirilmiş, ardından yapay zekâ destekli bir filtreleme mekanizması ile veri seti yeniden taranmış ve gerekli görülen örneklerde etiket düzeltmeleri uygulanmıştır. Bu yaklaşım, tamamen otomatik etiketlemeye dayalı sistemlerin aksine, insan denetimli (human-in-the-loop) bir veri iyileştirme süreci oluşturmayı amaçlamaktadır.

Ayrıca model geliştirme sürecinde farklı veri dengeleme yöntemleri, kayıp fonksiyonları ve model mimarileri karşılaştırmalı olarak analiz edilmiştir. Bu kapsamda, çok dilli Transformer modelleri ile Türkçe'ye özgü modeller karşılaştırılmıştır **[5]**. Özellikle oversampling yönteminin modelde ezberleme eğilimini artırdığı gözlemlenmiş ve bu durum deneysel olarak ortaya konulmuştur. Bu nedenle veri çoğaltma temelli yaklaşımlar yerine class-weight tabanlı yöntemler tercih edilmiştir.

Bu rapor, bitirme projesinin ikinci aşamasında gerçekleştirilen veri iyileştirme, model karşılaştırma ve deneysel analiz çalışmalarını kapsamaktadır. Çalışma kapsamında yalnızca model performansı değil, aynı zamanda veri kalitesi, etiket güvenilirliği ve model kararlılığı da değerlendirme kriterleri olarak ele alınmıştır. Projenin devamında ise, model kararlarının açıklanabilirliğini artırmak amacıyla literatürde yaygın olarak kullanılan SHAP, LIME ve Integrated Gradients gibi XAI yöntemlerinin uygulanması planlanmaktadır **[7] [8] [9]**.

1.1.1 Bilimsel Katkılar

Bu çalışma kapsamında aşağıdaki katkılar sağlanmıştır:

• Farklı kaynaklardan elde edilen Türkçe otel yorumları tek ve standart bir veri yapısında birleştirilmiştir.

• Otomatik etiketleme sürecinin sınırlılıkları analiz edilmiş ve veri seti manuel ve yapay zekâ destekli yöntemlerle yeniden düzenlenmiştir.

• Makine çevirisi içeren veri kaynaklarının model performansı üzerindeki etkisi deneysel olarak incelenmiş ve genellenebilirliği daha yüksek veri yapısı oluşturulmuştur.

• Oversampling gibi veri çoğaltma yöntemlerinin model üzerindeki etkileri değerlendirilmiş ve ezberleme (overfitting) problemi deneysel olarak ortaya konulmuştur.

• Farklı kayıp fonksiyonları (Weighted Cross Entropy, Focal Loss, Weight Smoothing) ve model mimarileri (BERTurk, XLM-RoBERTa, mDeBERTa-v3) karşılaştırmalı olarak analiz edilmiştir.

• İstatistiksel anlamlılık ve stabilite analizi kapsamında çoklu başlangıç tohumları (multi-seed) kullanılarak model performansının kararlılığı incelenmiştir.

• Yüksek doğruluk değerlerinden ziyade veri kalitesi, etiket güvenilirliği ve model genellenebilirliğini önceliklendiren, tekrarlanabilir ve sistematik bir deneysel süreç oluşturulmuştur.

Bölüm 2:

Literatür Taraması

2. Duygu Analizi Çalışmaları

Duygu analizi, metin madenciliği ve doğal dil işleme alanlarında yaygın olarak çalışılan temel problemlerden biridir. Kullanıcı yorumları, sosyal medya paylaşımları ve ürün değerlendirmeleri gibi metinler üzerinden duygu tespiti yapılması, karar destek sistemlerinde önemli bir rol oynamaktadır. Literatürde, özellikle turizm sektöründeki çevrimiçi şikâyetlerin ve geri bildirimlerin analizi; işletmelerin hizmet kalitesini değerlendirmesi, müşteri memnuniyetini ölçmesi ve müşteri sadakati oluşturması açısından kritik bir veri kaynağı olarak ele alınmaktadır **[1] [6]**. İlk dönem çalışmalarda ağırlıklı olarak sözlük tabanlı ve istatistiksel yöntemler kullanılırken, artan veri miktarı ve hesaplama gücüyle birlikte günümüzde derin öğrenme tabanlı yaklaşımlar yaygınlaşmıştır.

2.1 Türkçe Duygu Analizi ve Transformer Modeller

Türkçe, eklemeli bir dil olması nedeniyle morfolojik açıdan karmaşık bir yapıya sahiptir **[2]**. Bu durum, geleneksel makine öğrenmesi yöntemleriyle yüksek performans elde edilmesini zorlaştırmaktadır. Özellikle kelime kökleri ve eklerin anlam üzerindeki etkisi, bağlamsal temsillerin doğru biçimde öğrenilmesini gerekli kılmaktadır. Transformer tabanlı modeller, uzun menzilli bağımlılıkları ve bağlamsal ilişkileri başarılı şekilde modelleyebilmeleri sayesinde Türkçe duygu analizi çalışmalarında önemli avantajlar sunmaktadır **[3] [4]**. Türkçenin yapısal özelliklerine uygun olarak ön-eğitilmiş BERTurk gibi modeller ile diller arası transfer öğrenmesinde güçlü genelleme yeteneği sunan XLM-RoBERTa gibi çok dilli mimariler, sınırlı veriyle dahi başarılı sonuçlar elde edilebildiğini göstermektedir **[4] [5]**.

2.1.1 Açıklanabilir Yapay Zekâ Yaklaşımları

Derin öğrenme modellerinin yüksek performansına rağmen, karar süreçlerinin yorumlanabilir olmaması önemli bir sınırlılık olarak değerlendirilmektedir. Bu modellerin "kara kutu" niteliğini azaltmayı amaçlayan açıklanabilir yapay zekâ yaklaşımları, son yıllarda literatürde giderek daha fazla önem kazanmaktadır. SHAP, LIME ve Integrated Gradients gibi yöntemler, model tahminlerine hangi kelime veya özelliklerin ne ölçüde katkı sağladığını matematiksel olarak ortaya koyarak model davranışlarının daha şeffaf biçimde analiz edilmesine olanak tanımaktadır **[7] [8] [9]**. Özellikle turizm gibi doğrudan işletme kararlarını ve müşteri güvenini etkileyen alanlarda, bu yöntemler model çıktılarının güvenilirliğini ve kullanılabilirliğini artırmaktadır. Son yıllarda Transformer tabanlı modeller için geliştirilen açıklanabilirlik yöntemleri de literatürde araştırma odağı hâline gelmektedir **[11] [13]**.

Bölüm 3:

Metodoloji

3. Veri Toplama ve Veri Kaynakları

Bu çalışmada kullanılan Türkçe otel yorumları, birden fazla çevrimiçi kaynaktan elde edilmiştir. Veri seti, hem hazır veri kaynaklarından hem de manuel olarak web sitelerinden toplanan kullanıcı yorumlarının birleştirilmesiyle oluşturulmuştur. Bu yaklaşım, veri çeşitliliğini artırarak modelin farklı dil kullanım biçimlerine karşı daha genellenebilir hale gelmesini amaçlamaktadır. Bu çalışmada uygulanan veri işleme ve modelleme süreci Şekil 1'de özetlenmiştir.

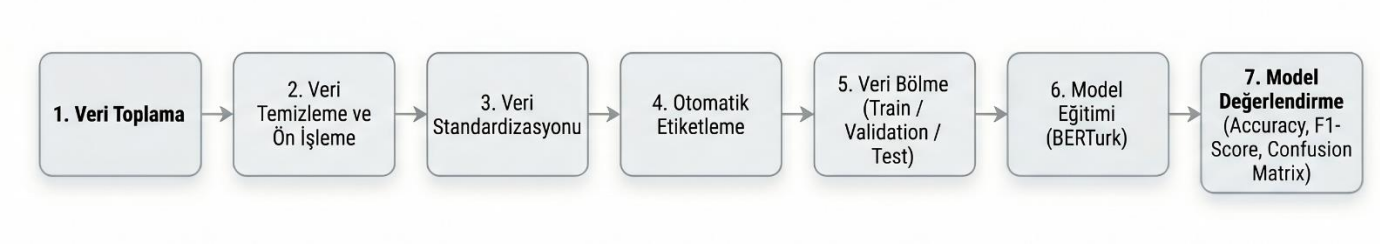

Şekil 1. Veri İşleme ve Modelleme Pipeline'ı

3.1 Kullanılan Veri Kaynakları

Çalışmada kullanılan veri kaynakları aşağıdaki gibidir:

• **Kaggle üzerinden temin edilen TripAdvisor veri seti:**

Toplam 5495 yorum içermektedir. İngilizce olan bu yorumlar Türkçeye çevrilerek veri setine dahil edilmiştir **[14]**. Çeviri işlemi sırasında Google Translate API kullanılmıştır. Ancak otomatik çeviri sürecinin dil yapısında bozulmalara ve anlam kaymalarına neden olabileceği literatürde de vurgulanmaktadır. Bu durumun model performansı üzerindeki etkisi çalışmanın ilerleyen aşamalarında deneysel olarak analiz edilmiştir.

• **Manuel olarak web sitelerinden toplanan Türkçe yorumlar:**

- Neredekal: 632 yorum
- Otelyorum ve Otelpuan: toplam 8906 yorum

Farklı kaynaklardan toplanan veriler ortak bir ön işleme hattında birleştirilerek boş satırlar, üç kelimeden kısa yorumlar ve mükerrer kayıtlar (duplicates) temizlenmiştir. Bu işlemler sonucunda analize esas teşkil eden 14.492 örnekten oluşan ham veri seti elde edilmiştir.

3.2 Veri Standardizasyonu

Farklı kaynaklardan elde edilen veriler aşağıdaki ortak veri şemasına dönüştürülmüştür:
hotel_name, comment_text, source_url, source, rating_auto, sentiment_label
Bu sayede farklı platformlardan gelen veriler tek bir model eğitim sürecinde kullanılabilir hale getirilmiştir.

3.3 Etiketleme Stratejisi

3.3.1 Üç Sınıflı Duygu Etiketleme

Duygu analizi problemi negatif, nötr ve pozitif olmak üzere üç sınıf altında ele alınmıştır. Puan bazlı otomatik etiketleme stratejisi aşağıdaki şekilde uygulanmıştır:
• 1–2 → Negatif
• 3 → Nötr
• 4–5 → Pozitif
1–10 aralığında verilen puanlar da bu sınıflara normalize edilmiştir.

3.3.2 Etiket Doğruluğu ve Veri Revizyon Süreci

İlk aşamada kullanılan otomatik etiketleme yaklaşımı hızlı veri üretimi sağlamasına rağmen, özellikle nötr sınıfta hatalı etiketlemelere neden olabilmektedir. Bu durum, model performansının yalnızca mimariye değil, veri kalitesine de doğrudan bağlı olduğunu göstermiştir. Bu kapsamda veri seti ikinci aşamada kapsamlı bir revizyon sürecinden geçirilmiştir. Yaklaşık 12.000 yorum üzerinde önce manuel inceleme yapılmış, ardından yapay zekâ destekli bir filtreleme yaklaşımı ile veri seti tekrar taranmıştır. Bu süreçte, model tahminleri ve metin içerikleri birlikte değerlendirilerek hatalı olduğu düşünülen etiketler düzeltilmiştir.

Ayrıca, kısa ve daha doğrudan ifade içeren yorumların etiketleme açısından daha tutarlı olduğu gözlemlenmiş ve veri temizleme stratejisi bu doğrultuda güncellenmiştir. Bu yaklaşım, tamamen otomatik etiketleme yerine insan denetimli (human-in-the-loop) bir veri iyileştirme süreci oluşturmayı amaçlamaktadır.

3.4 Veri Temizleme ve Ön İşleme

Veri seti üzerinde aşağıdaki ön işleme adımları uygulanmıştır:

- Boş ve anlamsız yorumların kaldırılması
- Tekrarlayan kayıtların (duplicate) silinmesi
- Metinlerin standart string formatına dönüştürülmesi
- CSV veri yapısına uyumlu hale getirilmesi

İkinci aşamada ise veri temizleme süreci genişletilmiş ve özellikle kısa yorumlar, mükerrer ifadeler ve düşük bilgi içeren metinler yeniden değerlendirilmiştir.

3.5 Kaggle Verisi ve Veri Kalitesi Analizi

Çalışmanın ilk aşamasında Kaggle veri setinden elde edilen ve otomatik olarak Türkçeye çevrilen yorumlar modele dahil edilmiştir. Bu veri seti ile yapılan ilk deneylerde yüksek doğruluk değerleri elde edilmiştir.

Ancak yapılan analizler sonucunda, makine çevirisi ile oluşturulan verilerin modelin belirli kalıpları öğrenmesine neden olduğu ve bu durumun performansı yapay olarak artırdığı gözlemlenmiştir. Bu nedenle, yalnızca doğruluk metriğine odaklanmanın yanıltıcı olabileceği değerlendirilmiştir.

Bu bulgu doğrultusunda, yalnızca doğal Türkçe yorumlardan oluşan veri setleri ile de deneyler gerçekleştirilmiş ve model performansı karşılaştırmalı olarak analiz edilmiştir.

3.6 Veri Bölme (Train / Validation / Test)

Veri seti stratified split yöntemi kullanılarak:

• %80 eğitim

• %10 doğrulama

• %10 test

olacak şekilde bölünmüştür. Bu yöntem sayesinde her alt veri kümesinde sınıf dağılımı korunmuş ve model değerlendirme sürecinde yanlılık oluşması engellenmiştir.

3.7 Sınıf Dengesizliği ve Veri Dengeleme Yöntemleri

Veri setinde sınıf dağılımının dengesiz olması (özellikle pozitif sınıfın baskın olması), model performansını doğrudan etkilemektedir.
Bu problemi çözmek amacıyla iki farklı yaklaşım değerlendirilmiştir:

3.7.1 Oversampling Yaklaşımı

İlk olarak azınlık sınıfların çoğaltılması (oversampling) yöntemi denenmiştir. Ancak bu yöntemde aynı veri örneklerinin tekrar kullanılması nedeniyle modelin overfitting (ezberleme) eğilimi gösterdiği gözlemlenmiştir. Model, eğitim verisini öğrenmek yerine belirli örnekleri hatırlamaya yönelmiş ve bu durum gerçek dünya verileri üzerinde genellenebilirliği olumsuz etkilemiştir.
Bu nedenle oversampling yöntemi terk edilmiştir.

3.7.2 Class-Weight Yaklaşımı

Alternatif olarak, sınıf dengesizliği problemi loss fonksiyonuna eklenen class-weight parametreleri ile ele alınmıştır. Bu yaklaşım, veri dağılımını değiştirmeden modelin azınlık sınıflara daha fazla önem vermesini sağlamaktadır. Transformer tabanlı modellerin eğitim sürecinde, sınıf dengesizliği problemini ele almak amacıyla loss fonksiyonuna dayalı ağırlıklandırma yaklaşımları yaygın olarak tercih edilmektedir **[12]**.

3.8 Model ve Eğitim Süreci

Çalışmada temel model olarak BERTurk-base kullanılmıştır **[4]**. Model eğitimi, Transformer tabanlı modeller için önerilen standart fine-tuning yaklaşımı ile gerçekleştirilmiştir **[3] [12]**. Eğitim sürecinde kullanılan hiperparametreler deneysel optimizasyonlar sonucunda belirlenmiştir. Nihai model için kullanılan temel hiperparametre değerleri aşağıdaki gibidir:

- Maksimum token uzunluğu (max_len): **384**
- Epoch sayısı: **5**
- Learning rate: **2e-05**
- Batch size: **16**

Bu parametreler, literatürde önerilen değerler doğrultusunda seçilmiş ve deneysel olarak optimize edilmiştir.

3.9 Loss (Kayıp) Fonksiyonlarının Karşılaştırmalı Analizi

Model performansını artırmak amacıyla farklı kayıp fonksiyonları karşılaştırmalı olarak analiz edilmiştir:

• Weighted Cross Entropy (WCE)

• Weight Smoothing (WCE_SMOOTH)

• Focal Loss

Yapılan deneylerde, Focal Loss'un bazı sınıflarda performansı artırırken genel dengeyi bozduğu, Weight Smoothing yönteminin ise sınıflar arası performans dağılımını etkilediği gözlemlenmiştir. Bu nedenle, en dengeli sonuçları veren Weighted Cross Entropy yöntemi tercih edilmiştir.

3.10 Model Karşılaştırmaları ve Stabilite Analizi

Çalışma kapsamında yalnızca tek bir model değil, farklı Transformer mimarileri de değerlendirilmiştir:

• BERTurk

• XLM-RoBERTa **[5]**

Bu modeller, farklı rastgele başlangıç değerleri (multi-seed) kullanılarak birden fazla kez eğitilmiştir. Bu yaklaşım, model performansının istatistiksel olarak anlamlı biçimde değerlendirilmesini sağlamakta ve rastlantısal faktörlerin sonuçlar üzerindeki etkisini azaltarak daha güvenilir ve genellenebilir bulgular elde edilmesine katkıda bulunmaktadır. mDeBERTa-v3 modeli de ön deneylerde değerlendirilmiş, ancak daha düşük ve kararsız sonuçlar nedeniyle detaylı analizlere dahil edilmemiştir.

Elde edilen bulgular, BERTurk modelinin Türkçe veri üzerinde daha kararlı ve dengeli sonuçlar verdiğini göstermiştir.

3.11 Donanım ve Eğitim Ortamı

Model eğitimleri farklı donanım ortamlarında gerçekleştirilmiştir. Deneylerin bir kısmı NVIDIA RTX 3050 Ti GPU ve 32 GB RAM kapasitesine sahip bir sistemde, diğer kısmı ise NVIDIA RTX 3060 GPU ve 16 GB RAM kapasitesine sahip bir sistemde yürütülmüştür. Her iki ortam da PyTorch tabanlı ve CUDA destekli olup, Transformer tabanlı modellerin etkin ve yüksek performanslı bir şekilde eğitilmesine olanak sağlamıştır.

Her bir model ve deney konfigürasyonu için eğitim süresi değişkenlik göstermiş olup, eğitimler yaklaşık 3 ila 15 saat arasında tamamlanmıştır. Bu süre farklılıkları; model mimarisi, hiperparametre ayarları, kullanılan donanım ve rastgele başlangıç değerlerinden kaynaklanmaktadır.

Deneyler farklı donanım ortamlarında gerçekleştirilmiş olmakla birlikte, tüm karşılaştırmalı analizlerde aynı eğitim protokolü, veri bölme stratejisi ve değerlendirme metrikleri korunarak sonuçların tutarlılığı, karşılaştırılabilirliği ve yeniden üretilebilirliği (reproducibility) sağlanmıştır.

Bölüm 4:

Bulgular ve Deney Sonuçları

Bu bölümde, önerilen metodoloji kapsamında gerçekleştirilen deneylerin sonuçları sunulmakta; farklı veri seti yapılandırmaları, model mimarileri ve eğitim stratejileri karşılaştırmalı olarak analiz edilmektedir. Elde edilen bulgular, yalnızca model performansını değil, aynı zamanda veri kalitesi, loss function seçimi ve eğitim stratejilerinin model davranışı üzerindeki etkisini de ortaya koymaktadır. Bölümde sunulan sonuçlar, proje sürecinde yapılan kontrollü deneyler ve çoklu tekrar koşuları ile elde edilen bulgulara dayanmaktadır.

4.1 Veri Kaynağının Model Performansına Etkisi (Kaggle Analizi)

Çalışmanın ilk aşamasında, makine çevirisi ile Türkçeye çevrilen Kaggle veri seti modele dahil edilmiştir. Ancak bu veri setinin model performansı üzerindeki etkisini incelemek amacıyla, Kaggle verisinin dahil edildiği ve çıkarıldığı iki farklı senaryo karşılaştırılmıştır. Sonuçlar Çizelge 1'de sunulmuştur.

Veri Kaynağının Model Performansına Etkisi

Model Durumu	Accuracy	Macro-F1	F1 (Nötr)	F1 (Negatif)
Kaggle Dahil (Çeviri + Doğal)	0.843	0.769	0.666	0.705
No-Kaggle (Sadece Doğal)	0.825	0.742	0.692	0.604

Çizelge 1: Veri Kaynağının Model Performansına Etkisi

Çizelge incelendiğinde, Kaggle verisinin dahil edilmesiyle genel Accuracy değerinin arttığı görülmektedir. Ancak daha ayrıntılı değerlendirme, bu artışın özellikle negatif sınıfta yoğunlaştığını ve modelin çeviri kaynaklı örüntülere duyarlı hale geldiğini göstermektedir. Buna karşılık, yalnızca doğal Türkçe yorumlardan oluşan veri seti ile eğitilen modelde nötr sınıf performansının arttığı gözlemlenmiştir. Bu durum, modelin gerçek dünya dil kullanımına daha iyi uyum sağladığını ve sınır örnekleri daha tutarlı şekilde öğrendiğini göstermektedir. Bu nedenle, daha düşük genel Accuracy değerine rağmen genellenebilirliği daha yüksek olan No-Kaggle veri yapısı tercih edilmiştir.

Veri Azaltma Süreci

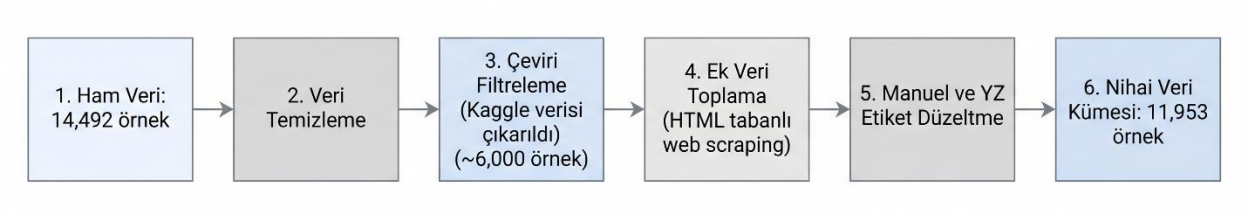

Şekil 2. Veri Azaltma Süreci

4.2 Loss Function Karşılaştırması

Sınıf dengesizliği problemini ele almak amacıyla farklı loss function yaklaşımları karşılaştırılmıştır. Aynı veri seti, aynı max length değeri ve sabit seed kullanılarak gerçekleştirilen deney sonuçları Çizelge 2'de verilmiştir. Bu deneyler, modelin özellikle nötr ve negatif sınıflardaki davranışını incelemek amacıyla tasarlanmıştır.

4.2.1 Focal Loss Eğitim Süreci

Focal Loss yönteminin eğitim süreci Şekil 3'te gösterilmektedir.

```
{'loss': 0.2616, 'grad_norm': 8.076253890991211, 'learning_rate': 1.188832487309645e-05, 'epoch': 2.03}
{'loss': 0.1914, 'grad_norm': 5.922150611877441, 'learning_rate': 1.1380710659898477e-05, 'epoch': 2.16}
{'loss': 0.1752, 'grad_norm': 14.766347885131836, 'learning_rate': 1.0873096446700509e-05, 'epoch': 2.28}
{'loss': 0.1781, 'grad_norm': 10.610748291015625, 'learning_rate': 1.036548223350254e-05, 'epoch': 2.41}
{'loss': 0.1693, 'grad_norm': 2.836620330810547, 'learning_rate': 9.857868020304569e-06, 'epoch': 2.54}
{'loss': 0.205, 'grad_norm': 3.284485340118408, 'learning_rate': 9.3502538071066e-06, 'epoch': 2.66}
{'loss': 0.2062, 'grad_norm': 4.946798324584961, 'learning_rate': 8.84263959390863e-06, 'epoch': 2.79}
{'loss': 0.1781, 'grad_norm': 0.6588089466094971, 'learning_rate': 8.335025380710661e-06, 'epoch': 2.92}
{'eval_loss': 0.3225211203098297, 'eval_accuracy': 0.7333333333333333, 'eval_f1_macro': 0.675967813030375, 'eval_f1_weig
hted': 0.751923227128278, 'eval_runtime': 68.6762, 'eval_samples_per_second': 19.657, 'eval_steps_per_second': 0.626, 'e
poch': 3.0}
{'train_runtime': 3343.6785, 'train_samples_per_second': 9.418, 'train_steps_per_second': 0.589, 'train_loss': 0.2903172
13071381, 'epoch': 3.0}
 60%|                                                                    | 1182/1970 [55:43<37:09,  2.83s/it]

[INFO] Evaluating on TEST...
100%|                                                                    | 43/43 [19:53<00:00, 27.75s/it]

[OK] Saved -> models\experiments_no_kaggle\bert-base-turkish-cased_len384_ep5_lr2e-05_lossfocal_seed42\test_report.txt

==============================
[SUMMARY] Mean ± Std over seeds
accuracy    : 0.7822 ± 0.0000
f1_macro    : 0.6990 ± 0.0000
f1_weighted : 0.7858 ± 0.0000
f1_negatif  : 0.6187 ± 0.0000
f1_notr     : 0.5655 ± 0.0000
f1_pozitif  : 0.9127 ± 0.0000
[OK] Summary saved -> models\experiments_no_kaggle\summary_bert-base-turkish-cased_len384_ep5_lossfocal.csv
==============================
```

Şekil 3. Focal Loss Eğitim Süreci

Eğitim logları incelendiğinde, validation performansının erken aşamada plato yaptığı ve modelin sonraki adımlarda anlamlı bir iyileşme üretemediği görülmektedir. Bu nedenle eğitim süreci early stopping mekanizması ile sonlandırılmıştır. Focal Loss yaklaşımı negatif sınıfta sınırlı bir iyileşme sağlasa da, nötr sınıfta belirgin performans kaybına yol açmıştır.

Loss Function Deney Sonuçları (Seed=42, Max Length=384)

Deney	**Accuracy**	**Macro-F1**	**F1 (Nötr)**	**F1 (Negatif)**
Weighted Cross Entropy (WCE)	0.809	0.726	0.655	0.605
Weight Smoothing (α=0.25)	0.805	0.725	0.644	0.616
Focal Loss (γ=2.0)	0.782	0.699	0.565	0.618

Çizelge 2: Loss Function Deney Sonuçları

Sonuçlar incelendiğinde:

- Focal Loss yöntemi negatif sınıfta iyileşme sağlasa da nötr sınıfta ciddi performans düşüşüne neden olmuştur.
- Weight Smoothing yöntemi sınıflar arasında dengesiz bir iyileşme sağlamıştır.
- En dengeli performans, tüm sınıflarda tutarlı sonuçlar veren Weighted Cross Entropy yöntemi ile elde edilmiştir.

Bu nedenle nihai model için WCE tercih edilmiştir.

4.3 Multi-Seed Stabilite Analizi ve Model Karşılaştırması

Model performansının rastlantısal faktörlerden etkilenmesini azaltmak amacıyla, modeller çoklu başlangıç tohumları (multi-seed) kullanılarak eğitilmiş ve ortalama sonuçlar ile standart sapmalar hesaplanmıştır.

BERTurk ve XLM-RoBERTa Modellerinin Karşılaştırmalı Performansı

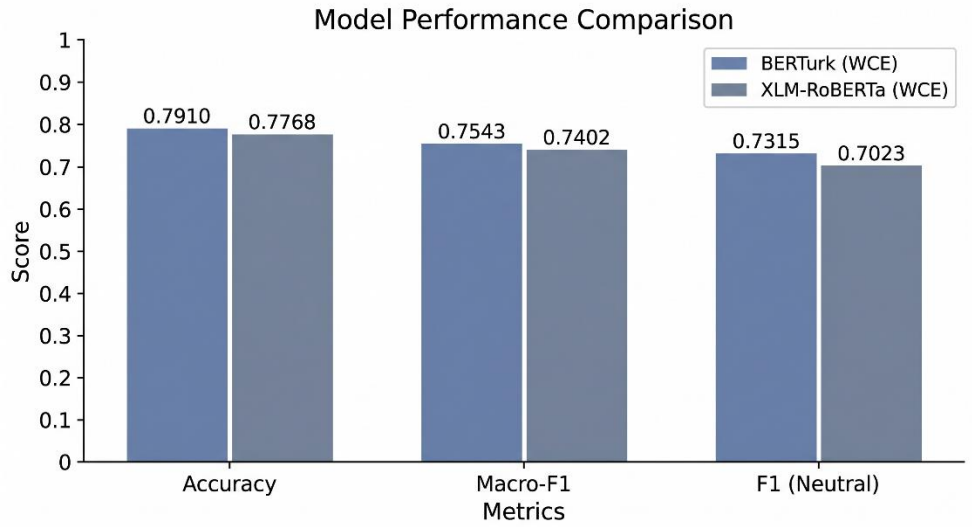

Şekil 4. BERTurk ve XLM-RoBERTa Modellerinin Karşılaştırmalı Performansı

Şekil 4’te, BERTurk ve XLM-RoBERTa modellerinin Accuracy, Macro-F1 ve F1 (Nötr) metrikleri açısından karşılaştırmalı performansları sunulmaktadır.

Model Karşılaştırması (Ortalama ± Standart Sapma)

Metrik	**BERTurk (WCE)**	**XLM-RoBERTa (WCE)**	**Fark**
Accuracy	0.7910 ± 0.0082	0.7768 ± 0.0123	+0.0142
Macro-F1	0.7543 ± 0.0069	0.7402 ± 0.0123	+0.0141
F1 (Nötr)	0.7315 ± 0.0147	0.7023 ± 0.0235	+0.0292
F1 (Negatif)	0.6188 ± 0.0150	0.6103 ± 0.0149	+0.0085

Çizelge 3: Model Karşılaştırması

Sonuçlar, BERTurk modelinin tüm metriklerde daha yüksek ortalama performans sergilediğini ve daha düşük standart sapma değerleri ile daha kararlı sonuçlar ürettiğini göstermektedir. Özellikle nötr sınıfta elde edilen fark, Türkçeye özgü dil yapısının model performansı üzerindeki etkisini açıkça ortaya koymaktadır.

4.4 Confusion Matrix Analizi

Bu matriste, doğal Türkçe yorumlardan oluşan No-Kaggle veri seti üzerinde Weighted Cross Entropy (WCE) ile eğitilen BERTurk modelinin sınıf bazlı tahmin performansı gösterilmektedir.

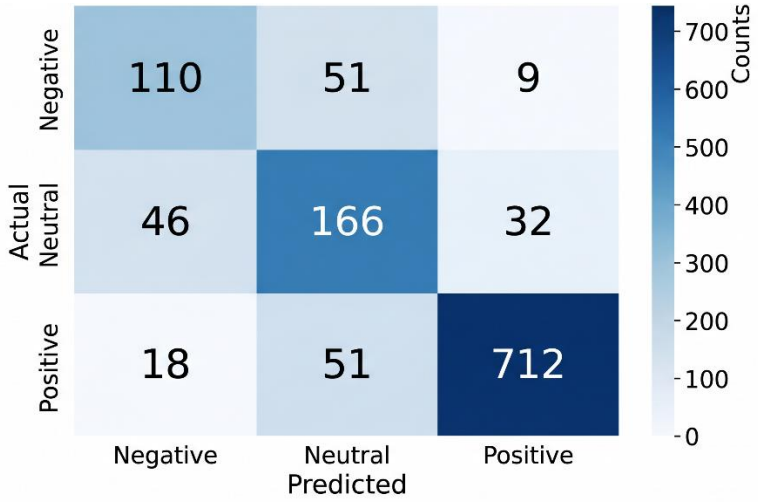

Şekil 5. WCE ile eğitilen BERTurk modeline ait confusion matrix (No-Kaggle)

Confusion matrix analizleri, modelin sınıf bazlı davranışını incelemek amacıyla gerçekleştirilmiştir. Analiz sonucunda, hata dağılımının homojen olmadığı görülmüştür. En yüksek hata, nötr sınıf örneklerinin negatif olarak tahmin edilmesi durumunda ortaya çıkmıştır (99 örnek). Ayrıca nötr sınıfın pozitif olarak tahmin edildiği 73 örnek de dikkat çekmektedir. Negatif sınıfın büyük ölçüde doğru öğrenildiği, ancak sınırlı sayıda örneğin nötr ile karıştırıldığı (29 örnek) görülmektedir. Pozitif sınıf ise 762 doğru tahmin ile en yüksek doğruluk oranına sahiptir.

Genel olarak modelin en çok zorlandığı ayrımın nötr sınıf ile diğer sınıflar arasında olduğu, özellikle nötr → negatif yönündeki hataların baskın olduğu gözlemlenmiştir. Bu durum, veri etiketleme sürecinin model performansı üzerindeki kritik etkisini göstermektedir.

4.5 Nihai Model Seçimi

Tüm deneysel sonuçlar birlikte değerlendirildiğinde, aşağıdaki yapı nihai model olarak seçilmiştir:

- Veri: Sadece doğal Türkçe yorumlar (No-Kaggle)
- Model: BERTurk-base
- Loss: Weighted Cross Entropy
- Eğitim: Multi-seed ortalama yaklaşımı

Bu yapı ile elde edilen ortalama performans:

- Accuracy: ~ 0.79
- Macro-F1: ~ 0.75

Bu sonuçlar, ilk aşamada elde edilen daha yüksek doğruluk değerlerine kıyasla her ne kadar daha düşük görünse de modelin genellenebilirliği ve gerçek dünya verilerine uyumu açısından daha güvenilir bir performans sunmaktadır.

Bölüm 5:

Tartışma, Sınırlamalar ve Gelecek Çalışmalar

5.1 Ana Bulguların Tartışılması

Bu çalışma kapsamında, Türkçe otel yorumları üzerinde gerçekleştirilen duygu analizi problemine yönelik yalnızca yüksek doğruluk odaklı bir model geliştirmek yerine; veri kalitesi, model kararlılığı ve genellenebilirlik odaklı bütüncül bir yaklaşım benimsenmiştir. Bölüm 4'te sunulan deneysel sonuçlar, farklı veri kaynakları, eğitim stratejileri ve model mimarilerinin performans üzerindeki etkisini açık biçimde ortaya koymuştur.
Bu çalışma kapsamında elde edilen en önemli bulgu, duygu analizi problemlerinde veri kalitesinin model mimarisinden daha belirleyici bir faktör olduğunu açık biçimde ortaya koymasıdır.
Bu doğrultuda elde edilen temel çıkarımlar aşağıda tartışılmaktadır:

Veri Kalitesi ve Genellenebilirlik İlişkisi
Makine çevirisi ile oluşturulan Kaggle veri setinin modele dahil edilmesi, genel doğruluk değerini artırmasına rağmen bu artışın modelin gerçek dil yapısını öğrenmesinden ziyade çeviri kaynaklı örüntüleri öğrenmesinden kaynaklandığı gözlemlenmiştir. Bu durum, yalnızca Accuracy metriğine dayalı değerlendirmelerin yanıltıcı olabileceğini göstermektedir.
Buna karşılık, yalnızca doğal Türkçe yorumlardan oluşan veri seti ile eğitilen model, özellikle nötr sınıfın tespitinde daha dengeli ve anlamlı sonuçlar üretmiştir. Bu bulgu, veri miktarının artırılmasından ziyade veri kalitesinin artırılmasının model genellenebilirliği üzerinde daha kritik bir rol oynadığını ortaya koymaktadır.

Loss Function Seçiminin Sınıf Performansına Etkisi
Farklı loss function yaklaşımlarının karşılaştırılması sonucunda, Focal Loss yönteminin negatif sınıf performansını kısmen artırmasına rağmen nötr sınıf performansında belirgin bir düşüşe neden olduğu gözlemlenmiştir. Bu durum, sınıflar arası ayrım sınırlarının belirsiz olduğu doğal dil işleme problemlerinde agresif odaklanma yöntemlerinin model dengesini bozabileceğini göstermektedir.
Weight Smoothing yaklaşımı sınırlı iyileşmeler sağlamakla birlikte genel performans açısından belirgin bir üstünlük ortaya koyamamıştır. Buna karşılık, Weighted Cross Entropy (WCE) yöntemi tüm sınıflarda daha dengeli ve tutarlı sonuçlar üretmiştir.

Bu bulgular, duygu analizi gibi çok sınıflı ve sınır durumların yoğun olduğu problemlerde dengeli öğrenme sağlayan klasik loss function yaklaşımlarının daha güvenilir sonuçlar verebileceğini doğrulamaktadır.

Dil Özelleşmesinin Model Performansına Etkisi

BERTurk ve XLM-RoBERTa modellerinin çoklu seed analizleri sonucunda, Türkçeye özgü olarak ön-eğitilmiş BERTurk modelinin hem ortalama performans hem de standart sapma açısından daha üstün olduğu görülmüştür.

Özellikle nötr sınıfta elde edilen performans farkı, Türkçenin morfolojik ve bağlamsal yapısının model performansı üzerinde doğrudan etkili olduğunu göstermektedir. Bu durum, dil-özel modellerin belirli görevlerde çok dilli modellere kıyasla daha başarılı olabileceğini desteklemektedir.

Nötr Sınıf Problemi ve Model Davranışı

Confusion matrix analizleri, modelin en fazla hatayı nötr sınıf ile diğer sınıflar arasında yaptığını göstermektedir. Nötr yorumların hem olumlu hem olumsuz ifadeler içerebilmesi, bu sınıfın sınır durum niteliği taşımasına neden olmaktadır.

Bu durum yalnızca bu çalışmaya özgü olmayıp, duygu analizi literatüründe de yaygın olarak karşılaşılan bir problemdir. Dolayısıyla elde edilen sonuçlar, model başarısızlığından ziyade problemin doğasından kaynaklanan bir zorluk olarak değerlendirilmelidir.

5.2 Teorik ve Operasyonel Sınırlamalar

Bu çalışma kapsamında elde edilen bulgular, belirli veri, etiketleme ve donanım koşulları altında değerlendirilmelidir. Bu nedenle, farklı veri dağılımları veya hesaplama ortamlarında model performansının değişkenlik gösterebileceği göz önünde bulundurulmalıdır.

Teorik Sınırlamalar

Duygu analizi problemlerinde kullanılan etiketleme yaklaşımı, kullanıcı puanlarının duygu sınıflarına dönüştürülmesine dayanmaktadır. Ancak doğal dilde duygu ifadeleri keskin sınırlar içermez ve aynı yorum içerisinde birden fazla duygu durumu bulunabilir.

Bu durum, özellikle nötr sınıfın tanımsal belirsizliğini artırmakta ve model performansını sınırlayan önemli bir faktör oluşturmaktadır. Ayrıca otomatik etiketleme süreçleri, insan yorumlarının karmaşıklığını tam olarak yansıtamayarak etiket gürültüsüne neden olabilmektedir.

Operasyonel Sınırlamalar

Model eğitimleri farklı donanım ortamlarında gerçekleştirilmiş olmakla birlikte, deneylerin her iki sistemde de tutarlı ve karşılaştırılabilir olmasını sağlamak amacıyla ortak bir paydada buluşulmuş ve tüm eğitim süreçlerinde en kısıtlı donanım parametreleri temel alınmıştır. Bu kapsamda:

• Maksimum token uzunluğu 384 ile sınırlandırılmıştır

• Batch size değeri 16 olarak belirlenmiştir

Daha uzun metin bağlamlarının (örneğin 512 token) veya daha büyük batch size değerlerinin model performansına etkisi mevcut donanım kısıtları nedeniyle test edilememiştir.

Buna ek olarak, çoklu seed analizleri ve farklı model/kayıp fonksiyonu kombinasyonlarının kapsamlı biçimde denenmesi yüksek hesaplama maliyeti gerektirdiğinden, değerlendirilebilecek hiperparametre kombinasyonları operasyonel olarak sınırlandırılmıştır.

5.3 Geleceğe Yönelik Araştırma Yol Haritası

Bu çalışma kapsamında oluşturulan veri seti, model altyapısı ve deneysel çerçeve, projenin sonraki aşamaları için güçlü bir temel oluşturmaktadır.

Açıklanabilir Yapay Zekâ (XAI) Entegrasyonu

Nihai model üzerinde SHAP, LIME ve Integrated Gradients yöntemleri uygulanarak modelin karar süreçleri analiz edilecektir. Bu sayede modelin hangi kelime veya ifadeler üzerinden karar verdiği görselleştirilecek ve model davranışı daha şeffaf hale getirilecektir.

Hata Analizi ve Dilsel İnceleme

Yanlış sınıflandırılan örnekler detaylı olarak incelenerek modelin zorlandığı dil yapıları analiz edilecektir. Bu analizler, model performansını artırmaya yönelik yeni veri işleme stratejilerinin geliştirilmesine katkı sağlayacaktır.

Model ve Veri Genişletme Çalışmaları

Daha büyük veri setleri ile eğitim, farklı Transformer mimarilerinin değerlendirilmesi ve veri zenginleştirme yöntemlerinin uygulanması planlanmaktadır.

Sektörel Uygulama Geliştirme

Elde edilen model çıktıları ve XAI analizleri kullanılarak, turizm sektörüne yönelik veri odaklı bir karar destek sistemi geliştirilmesi hedeflenmektedir.

5.4 Genel İlerleme Değerlendirmesi ve Zaman Çizelgesine Uyum

Proje ilerleyişi, TÜBİTAK 2209-A başvurusunda sunulan zaman çizelgesiyle genel hatlarıyla uyumlu bir seyir izlemektedir. Projenin temel taşlarını oluşturan; veri toplama, temizleme, etiket optimizasyonu ve deneysel altyapının kurulumu başarıyla tamamlanmıştır. Eğitim fazında ise BERTurk ve XLM-RoBERTa modelleri üzerinde geniş kapsamlı karşılaştırmalı analizler yürütülmüş ve projenin ana omurgası kurulmuştur.

Çalışmanın mevcut aşamasında, takvimde öngörüldüğü üzere model performansının genellenebilirliğini artırmak ve nötr sınıf ayrımını kesinleştirmek adına "model stabilizasyonu" çalışmalarına odaklanılmıştır. Eğitim sürecinde hedeflenen doygunluğa ulaşılması için yürütülen bu optimizasyon çalışmaları, takvimin bu diliminde planlı bir yoğunlaşma gerektirmiştir. Mevcut ivme korunarak, projenin ikinci yarısında hedeflenen Açıklanabilir Yapay Zekâ (XAI) entegrasyonu ve sektörel sonuç raporlama adımlarına takvime uygun şekilde geçilmesi öngörülmektedir.

TEŞEKKÜR

Bu çalışmanın gerçekleştirilmesi sürecinde değerli katkıları ve yönlendirmeleri için danışman hocamız sayın İlkay Yelmen'e teşekkür ederiz.

EK

EK-1. Test Kümesi Sınıflandırma Raporu

Sınıf	Precision	Recall	F1-score	Support
Negatif	0.63	0.65	0.64	170
Nötr	0.72	0.68	0.70	244
Pozitif	0.92	0.91	0.91	781
Accuracy	-	-	**0.795**	1195
Macro-F1	-	-	**0.750**	1195

Çizelge 4: Test Kümesi Sınıflandırma Raporu

EK-2: Confusion Matrix

Gerçek Sınıf \ Tahmin Edilen Sınıf	Negatif	Nötr	Pozitif
Negatif	110	51	9
Nötr	46	166	32
Pozitif	18	51	712

Çizelge 5: Confusion Matrix

EK-3: Veri Bölme ve Sınıf Dağılımı

Küme	Pozitif	Nötr	Negatif	Toplam
Train	6248	1951	1364	9563
Validation	781	244	170	1195
Test	781	244	170	1195

Çizelge 6: Veri Bölme ve Sınıf Dağılımı

EK-4: Veri Toplama Sürecinin Özeti

Bu çalışmada otel yorumları, Python programlama dili kullanılarak geliştirilen betikler aracılığıyla toplanmıştır. Web sayfalarından veri çekmek için *requests* ve *BeautifulSoup* gibi yaygın Python kütüphaneleri kullanılmıştır. Ban riskini azaltmak amacıyla tarayıcı benzeri HTTP başlıkları tanımlanmış ve istekler arasında rastgele bekleme süreleri uygulanmıştır. Buna ek olarak, Kaggle üzerinden temin edilen hazır veri setleri kullanılmış ve İngilizce içerikler Türkçeye çevrilerek veri setine dahil edilmiştir. Toplanan tüm veriler CSV formatında saklanmış ve ön işleme aşamasında temizlenerek nihai veri setine dahil edilmiştir.

EK-5: Kullanılan Python Kütüphaneleri

Kategori	Kütüphane	Açıklama
Dosya & Yol Yönetimi	pathlib	Dosya ve klasör işlemleri
Sayısal Hesaplama	math	Matematiksel işlemler
Rastgelelik & Zaman	random, time	Bekleme süreleri, rastgelelik
Metin İşleme	re	Düzenli ifadeler ile metin temizleme
Veri İşleme	pandas	Veri okuma, birleştirme ve ön işleme
Sayısal Diziler	numpy	Sayısal veri işlemleri
Web Veri Toplama	requests	HTTP istekleri
Web Veri Ayrıştırma	BeautifulSoup (bs4)	HTML ayrıştırma
Otomatik Çeviri	deep_translator	İngilizce yorumların Türkçeye çevrilmesi
Makine Öğrenmesi	scikit-learn	Veri bölme, class-weight hesaplama
Derin Öğrenme	torch, torch.nn, torch.cuda	GPU üzerinde model eğitimi
NLP Veri Yapıları	datasets	HuggingFace veri yapıları
Transformer Modeller	transformers	BERTurk modeli, tokenizer, Trainer
Performans Ölçümü	sklearn.metrics	Accuracy, F1, Confusion Matrix
Model Eğitimi API	transformers (Trainer, TrainingArguments)	Model eğitimi, değerlendirme ve hiperparametre yönetimi
Donanım Hızlandırma	CUDA	GPU üzerinde hızlandırılmış model eğitimi

Çizelge 7: Kullanılan Python Kütüphaneleri

KAYNAKLAR

[1]

B. A. Sparks and V. Browning, "Complaining in cyberspace: The motives and forms of hotel guests' complaints online," *Journal of Hospitality Marketing & Management*, vol. 19, no. 7, pp. 797–818, 2010.

[2]

E. Demirtaş and M. Pechenizkiy, "Sentiment analysis of Turkish texts," in *Proceedings of the 21st International Conference on Pattern Recognition (ICPR)*, Tsukuba, Japan, 2012, pp. 1–4.

[3]

J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*, Minneapolis, MN, USA, 2019, pp. 4171–4186.

[4]

S. Schweter, "BERTurk: BERT models for Turkish," *arXiv preprint arXiv:2005.03713*, 2020.

[5]

A. Conneau, K. Khandelwal, N. Goyal, et al., "XLM-RoBERTa: A massively multilingual pre-trained transformer," *arXiv preprint arXiv:1911.02116*, 2020.

[6]

L. Xiong, X. Wang, L. Yang, and Y. Yu, "Mining online reviews for customer sentiment analysis in tourism," *Tourism Management*, vol. 68, pp. 301–312, 2018.

[7]

S. M. Lundberg and S. I. Lee, "A unified approach to interpreting model predictions," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, Long Beach, CA, USA, 2017, pp. 4765–4774.

[8]

M. T. Ribeiro, S. Singh, and C. Guestrin, "'Why should I trust you?' Explaining the predictions of any classifier," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, CA, USA, 2016, pp. 1135–1144.

[9]
M. Sundararajan, A. Taly, and Q. Yan, “Axiomatic attribution for deep networks,” in *Proceedings of the 34th International Conference on Machine Learning (ICML)*, Sydney, Australia, 2017, pp. 3319–3328.

[10]
A. Özçift, “Explainable artificial intelligence approaches in Turkish text classification,” *Journal of Information Science*, vol. 48, no. 6, pp. 789–804, 2022.

[11]
C. Sun, L. Huang, and X. Qiu,
“Utilizing BERT for Aspect-Based Sentiment Analysis via Constructing Auxiliary Sentence,”
in Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT),
Minneapolis, MN, USA, 2019.

[12]
T. Wolf et al.,
“Transformers: State-of-the-Art Natural Language Processing,”
in Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP), 2020.

[13]
M. Danilevsky et al.,
“A Survey of the State of Explainable AI for Natural Language Processing,”
arXiv preprint arXiv:2008.00709, 2020.

[14]
Google, “Google Translate API,” https://cloud.google.com/translate
(accessed Jan. 17, 2026).
The service was accessed programmatically using the deep-translator Python library.

[15]
A. Minaee, N. Kalchbrenner, E. Cambria, N. Nikzad, M. Chenaghlu, and J. Gao,
“Deep Learning-Based Text Classification: A Comprehensive Review,”
ACM Computing Surveys, vol. 54, no. 3, pp. 1–40, 2021.

[16]
K. Clark, M. T. Luong, Q. V. Le, and C. D. Manning,
"ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators,"
in Proc. International Conference on Learning Representations (ICLR), 2020.